Classificação de Instrumentos Musicais: Uma Análise Comparativa entre Modelos Clássicos e Deep Learning via Espectrogramas

Arthur Santos Almeida
IEEE Control Systems Society (CSS) Student Chapter
Universidade de Brasília (UnB)
Email: arthursalmeidacontato@gmail.com

***Abstract*—A classificação automática de sinais de áudio é um processo relevante no que tange ao Aprendizado de Máquina. Este trabalho abrange uma abordagem baseada em aprendizado profundo para a classificação de áudios em comparação a um baseline fundamentado em árvores de decisão. A metodologia desenvolvida transforma os sinais de áudio em espectrogramas, o que permite tratá-los como imagens e realizar sua classificação por meio de redes neurais convolucionais. Além disso, comparamos essa rede complexa com um baseline de arquitetura baseada em Extração de Características Clássica através de vetores numéricos. Essa comparação produz a reflexão sobre qual abordagem é mais adequada e se a complexidade de um modelo efetivamente garante sua precisão classificatória. Os resultados demonstram que o uso da abordagem baseada em espectrogramas é superior na captura de padrões temporais e frequenciais complexos, superando o baseline de MFCC em termos de robustez frente ao ruído, embora demande um custo computacional mais elevado.**

***Index Terms*—Árvores de Decisão, Espectrogramas, Redes Neurais Convolucionais, Deep Learning, Classificação de Áudio, ResNet50, MFCCs**

I. Introdução

A Inteligência Artificial dedica-se à automatização de processos e à análise preditiva de padrões em conjuntos de dados conexos. Compreender a dinâmica dos classificadores é crucial não apenas para entender a lógica de padrões abstratos, mas para a avaliação de previsões em situações reais. Nesse contexto, a análise comparativa entre diferentes níveis de complexidade algorítmica torna-se essencial para validar a pertinência de cada modelo, garantindo que a automatização auxilie efetivamente na análise e classificação dos dados, mas ainda, na extração de correlações não triviais que escapariam à inspeção estatística clássica.

Nesse sentido, a democratização de algoritmos de aprendizado profundo, especificamente as Redes Neurais Convolucionais (CNNs)[1], permitiu a interpretação automatizada de padrões complexos, como os sinais acústicos de instrumentos musicais abordados neste projeto. A metodologia desenvolvida concentrou-se no processamento bidimensional de espectrogramas para alimentação da rede. Em paralelo, estabeleceu-se um baseline fundamentado na Extração de Características Clássica (vetores numéricos de características), visando confrontar o desempenho de uma arquitetura robusta contra métodos tradicionais e menos onerosos computacionalmente.

Diante disso, essa comparação é fundamental para determinar se o incremento na complexidade do modelo resulta em ganhos de precisão que justifiquem o maior custo de processamento. Os resultados obtidos indicam que, embora o baseline clássico apresente eficiência em cenários controlados, a abordagem baseada em aprendizado profundo demonstra uma superioridade significativa na generalização de dados complexos. Portanto, a escolha do classificador deve ser pautada pelo equilíbrio entre a acurácia necessária e as restrições de hardware, validando a robustez das CNNs para aplicações de alta complexidade.

II. Fundamentação Teórica

O desenvolvimento de um classificador de borda exige a interação entre os princípios básicos da física ondulatória, o processamento digital de sinais (DSP) e a teoria da otimização estocástica que rege as redes neurais artificiais.

Além disso, para entender como a energia sonora é liberada ao longo dos espectros vibratórios, emprega-se a análise de Fourier. A Transformada de Fourier (TF) contínua assume que qualquer sinal genérico $x(t)$ pode ser decomposto em uma soma de componentes harmônicas senoidais:

$$X(\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t}dt \tag{1}$$

Todavia, a TF assume estacionaridade, inadequada para o estudo dos eventos acústicos transientes. A Transformada de Fourier de Tempo Curto (STFT) mitiga essa limitação ao fatiar o sinal com janelas deslizantes:

$$X(m,\omega) = \sum_{n=-\infty}^{\infty} x[n]w[n-m]e^{-j\omega n} \tag{2}$$

onde $x[n]$ é a amostra discreta e $w[n-m]$ a função de janelamento. O espectrograma, dado por $S(m,\omega) = |X(m,\omega)|^2$, fornece uma representação bidimensional da energia ao longo do domínio do tempo e da frequência [8], permitindo o uso de CNNs originalmente projetadas para imagens.

No contexto dessas redes, a arquitetura ResNet [5] aborda o problema do desvanecimento do gradiente em redes profundas por meio de conexões residuais, conforme ilustrado na arquitetura geral da Figura 4:

$$y = \mathcal{F}(x, W_i) + x \tag{3}$$

Nessa formulação, detalhada no bloco residual da Figura 4, a saída de um bloco é composta pela soma entre a transformação aprendida $F(x)$ e a própria entrada x. Isso cria caminhos diretos para a propagação do gradiente durante o treinamento, preservando a informação ao longo das camadas e tornando o processo mais estável e eficiente.

Como entrada, o *baseline* utiliza os MFCCs (Mel-Frequency Cepstral Coefficients). Ao invés de receber a imagem de energia do sinal, recebe um vetor numérico de características tentando imitar a percepção auditiva, condensando a informação do espectrograma em poucos coeficientes, característica que pode ser visualizada na Figura 2.

Para a extração dos MFCCs, é necessário aplicar a Transformada Discreta de Cossenos (DCTs) ao logaritmo do espectro de mel:

$$C_n = \sum_{m=1}^{M} \log(S_m) \cos\left[n\left(m - \frac{1}{2}\right)\frac{\pi}{M}\right] \tag{4}$$

Sob esse prisma, o MFCC extrai a variação das ondas sonoras de cada instrumento e fornece uma característica numérica sobre o sinal sonoro. Para adequar o sinal à entrada do classificador clássico, aplica-se uma redução de dimensionalidade temporal através da média dos coeficientes. Isso permite que o modelo processe uma assinatura única e compacta do evento sonoro, ignorando variações transientes em favor do conteúdo timbrístico médio, para assim, classificá-los pelo conjunto das árvores de decisão da *Random Forest*, cuja lógica de ramificação é apresentada na Figura 1.

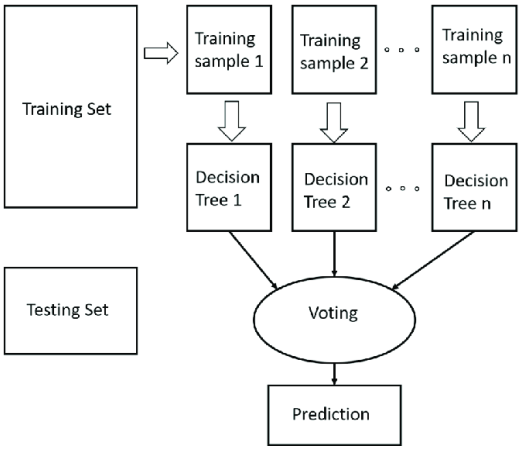

Fig. 1. Arquitetura Clássica da RandomForest: mostrando a funcionalidade do modelo, como um modelo simples de classificação.

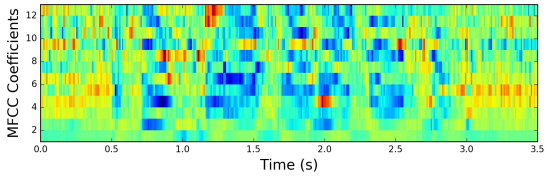

Fig. 2. Exemplo de representação visual dos MFCCs: o mapeamento de características do áudio através do tempo.

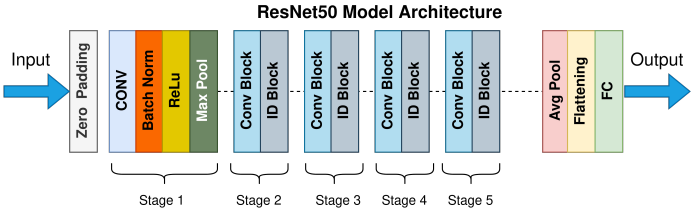

Fig. 3. Arquitetura original da ResNet, mostrando o uso de conexões residuais que permitem treinar redes profundas sem degradação.

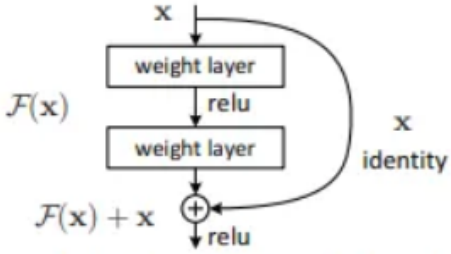

Fig. 4. Bloco residual básico: a saída é a soma da transformação $\mathcal{F}(x)$ com a entrada x, criando um atalho que facilita a propagação do gradiente.

Em suma, enquanto o *baseline* baseia-se em uma compressão estatística manual pela captura da média de variações dos MFCCs, a arquitetura ResNet opera sobre a representação densa do espectrograma, delegando às camadas convolucionais a tarefa de extrair padrões hierárquicos de alta complexidade.

III. Comparativo Metodológico

A metodologia desenvolvida neste trabalho seguiu um caráter de ramificação comparativa. O pipeline foi estruturado em três frentes principais:

- Geração, pré-processamento e regularização acústica dos sinais sonoros;
- Extração de características vetoriais unidimensionais para a classificação via árvores de decisão;
- Conversão espectral bidimensional para a classificação via redes neurais convolucionais.

Essa abordagem em paralelo garante que a comparação entre a extração clássica de características e a inferência profunda ocorra sob a mesma base de dados, isolando o impacto da representação dimensional do sinal acústico.

A. *Dataset e Regularização Acústica (Aumento de Dados)*

O treinamento robusto de arquiteturas de Aprendizado Profundo exige um volume substancial de dados para evitar a memorização e o sobreajuste (*overfitting*). Neste trabalho, utilizou-se o conjunto de dados público [2] *Instrument Recognition in Musical Audio Signals* (IRMAS), composto por arquivos de áudio distribuídos em 11 classes de instrumentos

TABLE I
COMPARATIVO ESTRUTURAL: MODELO BASELINE (RANDOM FOREST) *versus* PARADIGMA ESPECTRAL (CNN).

Métrica Arquitetural	***Árvore de Decisão***	***Espectrograma Visão***
Representação	Vetor 1D (MFCC)	Gráfico 2D (Espectrograma)
Dimensão de Entrada	40 Atributos	$3 \times 224 \times 224$ (RGB)
Complexidade	100 Árvores	50 Camadas Convolucionais
Parâmetros	≈ 150.000 Nós	$\approx 23,5$ Milhões
Tamanho em Disco	≈ 4 **MB**	≈ 98 MB

musicais. Os dados originais foram particionados em uma proporção aproximada de 70-15-15 para as etapas de treinamento, validação e teste.

Esse particionamento resultou em um subconjunto de treinamento com apenas 4.688 amostras originais, quantitativo insuficiente para a convergência otimizada de uma rede convolucional profunda. Para mitigar essa limitação, implementou-se uma rotina de *Data Augmentation* baseada em mascaramento acústico e variação dos tensores. Através do processamento direto dos espectrogramas Mel, aplicou-se o Mascaramento de Frequência (*Frequency Masking*) e o Mascaramento de Tempo (*Time Masking*)[7], [6], além de distorções de brilho e contraste (*Color Jitter*).

Para garantir o rigor científico e evitar o vazamento de informações (*data leakage*), as transformações sintéticas foram estritamente isoladas no conjunto de treinamento. Os conjuntos de validação e teste permaneceram com os dados íntegros e originais. Conforme ilustrado na Figura 5, essa técnica de regularização acústica expandiu exponencialmente a base de treinamento de 4.688 para 37.504 amostras, conferindo maior variância à base e forçando o modelo a aprender as assinaturas timbrísticas essenciais.

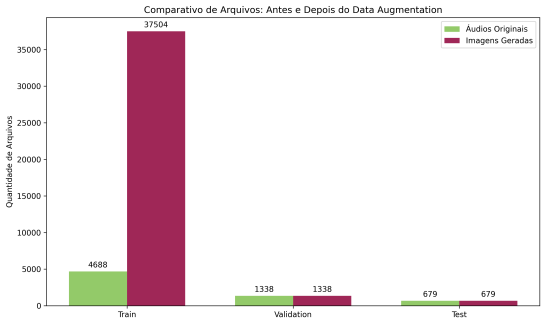

Fig. 5. Comparativo do volume de amostras antes e após o *Data Augmentation*. A técnica foi restrita ao conjunto de treinamento para evitar contaminação de dados.

B. Modelo Baseline: Random Forest

Para o estabelecimento de um patamar de comparação, implementou-se um modelo de referência baseado em algoritmos de aprendizado supervisionado clássico. O processo inicia-se com a extração de características da onda sonora bruta, convertendo o sinal em um vetor numérico de 40 Coeficientes Cepstrais de Frequência Mel (MFCCs)[3]. Para reduzir a dimensionalidade e focar no conteúdo timbrístico médio, aplica-se uma média aritmética sobre o eixo temporal, resultando em uma assinatura estática de 40 atributos por amostra.

A classificação é executada por um comitê de *Random Forest* [4] composto por 100 árvores de decisão independentes. Durante a fase de treinamento, o algoritmo avalia recursivamente qual coeficiente oferece a melhor separação estatística entre as classes em cada nó, estabelecendo limiares binários de decisão. A predição final de um novo vetor de áudio é determinada por votação majoritária entre todas as árvores da floresta.

1) Considerações sobre o modelo Baseline: A análise do desempenho do modelo clássico revelou um cenário de sobreajuste (*overfitting*) acentuado. o modelo atingiu uma acurácia de treinamento de 99,89%, mas demonstrou baixa capacidade de generalização, com apenas 54,61% de acurácia no conjunto de validação e um *F1-Score* global de 0,5367.

- **Eficiência Computacional:** Apresenta baixo custo de processamento, permitindo treinamento e inferência em CPU sem a necessidade de aceleração por hardware especializado.
- **Sensibilidade ao Ruído:** A redução dos MFCCs à média temporal elimina nuances dinâmicas e ataques transientes do som, dificultando a distinção entre instrumentos com sobreposição harmônica, como flauta e clarinete.
- **Simplicidade Estrutural:** Embora ofereça prototipação rápida, a arquitetura mostra-se insuficiente para capturar a complexidade acústica necessária para alta precisão em ambientes de áudio reais.

A redução dos MFCCs à média temporal elimina nuances dinâmicas e ataques do som. Conforme evidenciado na matriz de confusão (Figura 6), isso dificulta severamente a distinção entre instrumentos com envelopes harmônicos sobrepostos, gerando alta taxa de falsos preditivos entre classes como guitarra elétrica, voz e instrumentos de sopro.

C. Modelo Robusto: ResNet50

A Figura 7 ilustra o formato de entrada adotado, onde o sinal de áudio é convertido em um espectrograma Mel bidimensional. Essa transformação mapeia frequências e amplitudes ao longo do tempo em tensores RGB de $3 \times 224 \times 224$. O mapeamento visual permite que a arquitetura interprete características acústicas como padrões de textura complexos, capturando nuances que a extração vetorial unidimensional ignora.

A arquitetura empregada foi a *ResNet50*, utilizando a técnica de *Transfer Learning* com pesos pré-treinados no *dataset ImageNet*. Para a especialização no domínio musical, implementou-se o congelamento das camadas convolucionais iniciais, realizando o *Fine-Tuning* especificamente nos blocos residuais terminais (*layer3* e *layer4*). A camada linear de saída foi

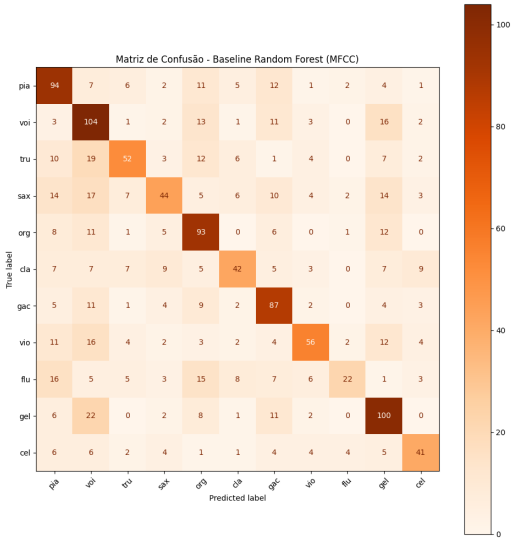

Fig. 6. Matriz de Confusão do modelo *Baseline* (Random Forest). Nota-se a dispersão das predições fora da diagonal principal, evidenciando a limitação da média de MFCCs em separar classes acusticamente similares.

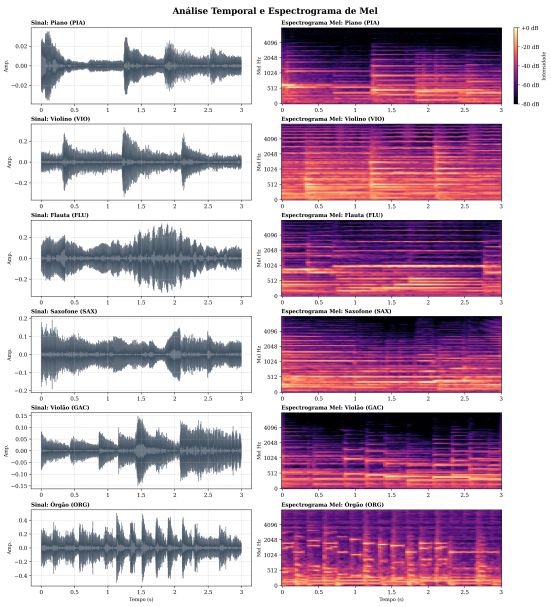

Fig. 7. Representação visual da entrada: Espectrogramas Mel processados com colormap *magma*, destacando as diferentes texturas harmônicas entre instrumentos percussivos e de sopro.

reestruturada para as 11 classes do projeto, precedida por uma etapa de regularização via *Dropout* em 50%.

1) Considerações sobre o modelo ResNet50: A aplicação do aprendizado profundo demonstrou uma superioridade estatística robusta frente ao *baseline*. Conforme evidenciado nas curvas de aprendizado, o modelo apresentou convergência estável a partir da época 25, atingindo uma acurácia de treinamento final de 98,36%, uma acurácia de validação de 89.01%.

- **Alto Poder de Classificação:** O modelo alcançou uma acurácia global de 87,30% no conjunto de teste e um *F1-Score* ponderado de 0,8735, superando drasticamente os 54,61% do modelo clássico.
- **Discriminação Timbrística:** A análise detalhada indica um desempenho excepcional em classes com assinaturas visuais nítidas, como Voz (*F1-Score* de 0,96) e Piano (*F1-Score* de 0,93). Por outro lado, desafios persistem em instrumentos com alta sobreposição harmônica, como Saxofone e Guitarra Elétrica, que registraram *F1-Scores* de 0,79 e 0,80, respectivamente.
- **Custo Computacional:** A rede exige aceleração via hardware dedicado (GPU) para gerenciar seus mais de 23 milhões de parâmetros, ocupando $\approx$ 98 MB em disco.

D. Síntese Comparativa das Arquiteturas

Para consolidar a análise entre os dois modelos desenvolvidos, a Tabela II sintetiza o salto qualitativo de precisão obtido.

TABLE II
COMPARATIVO DE DESEMPENHO GLOBAL: BASELINE VS. RESNET50

Métrica de Avaliação	Random Forest	ResNet50
Acurácia de Treinamento	99,89%	98,36%
Acurácia de Validação	54,61%	89,01%
Acurácia Global (Teste)	**53,00%**	**87,30%**
F1-Score	0,5367	0,8735

Apoiando-se nestas métricas e nas diferenças de arquitetura destacadas na Tabela I, fica evidente que a transição de um vetor de características unidimensional para um tensor bidimensional acarreta um aumento expressivo na densidade de processamento. Embora o *baseline* seja significativamente mais leve e amigável para dispositivos com restrição de memória, a arquitetura *ResNet50* justifica sua massiva carga de parâmetros (mais de 23 milhões) pela capacidade superior de mapear as texturas complexas dos timbres musicais. Dessa forma, a rede convolucional consagra-se como a escolha ideal em cenários onde a robustez e a precisão classificatória se sobrepõem à economia de espaço em disco.

IV. ANÁLISE DOS RESULTADOS E DISCUSSÕES

A. Limitações da Abordagem Clássica

A avaliação do *baseline* revelou um claro cenário de sobreajuste (*overfitting*). O modelo estatístico decorou as amostras de treinamento, atingindo 99,89% de acurácia, mas fracassou ao tentar generalizar para dados inéditos, limitando-se a 54,61% no conjunto de validação.

Ao analisar a matriz de confusão (Figura 6), nota-se uma grande dispersão das predições fora da diagonal principal. O achatamento dos vetores MFCC pela média temporal elimina a dinâmica do ataque e decaimento das notas musicais. Essa compressão forçou o modelo a confundir sistemicamente instrumentos com envelopes harmônicos de mesma faixa de frequência, apresentando alta taxa de falsos positivos entre a Guitarra Elétrica (*gel*) e o Violão Acústico (*gac*), e entre a Flauta (*flu*) e o Clarinete (*cla*).

B. Desempenho e Convergência da ResNet50

Em contrapartida, o treinamento da *ResNet50* apresentou convergência estável e superou amplamente o *baseline* de *Random Forest*. Conforme ilustrado nas curvas de aprendizado (Figura 8), a rede otimizou sua função de perda sem apresentar divergências abruptas, atingindo 98,36% de acurácia de treino.

A conversão do áudio para espectrogramas Mel permitiu que a rede convolucional extraísse texturas em múltiplas camadas, elevando a acurácia global de 53% para patamares de 87,30%

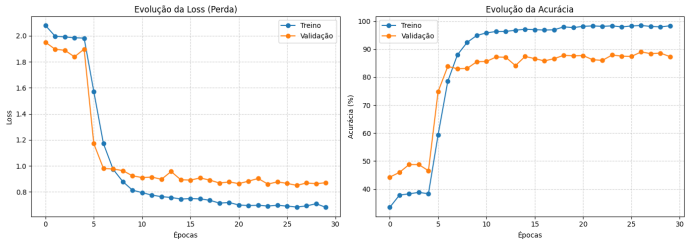

Fig. 8. Evolução da função de perda (Loss) e Acurácia durante o treinamento da ResNet50, demonstrando convergência estável.

no conjunto de teste isolado. O *F1-Score* ponderado consolidou-se em 0,8735, comprovando a eficácia da técnica de *Fine-Tuning*. Apesar de exigir maior custo computacional e memória dedicada, o ganho expressivo de precisão justifica o uso de *Deep Learning* para o reconhecimento de timbres.

C. Capacidade Discriminativa por Textura

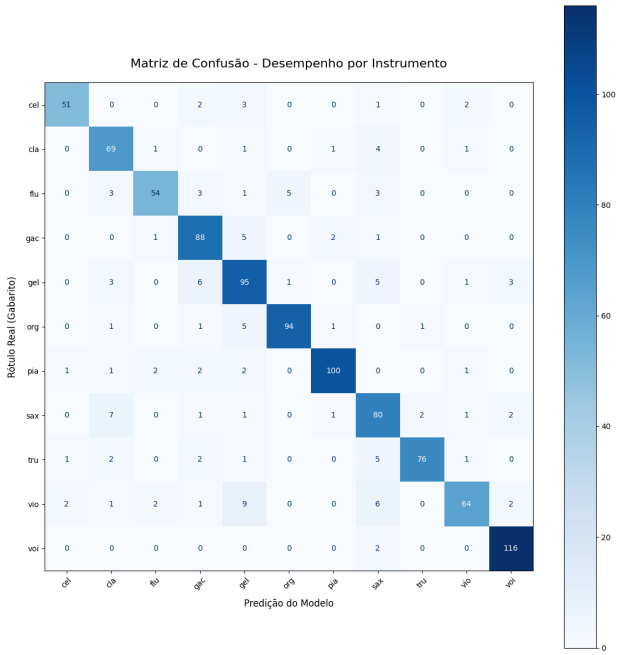

Fig. 9. Matriz de Confusão da ResNet50. O adensamento na diagonal principal reflete o alto índice de acertos por classe comparado ao baseline.

A análise da matriz de confusão da rede convolucional (Figura 9) destacou a alta precisão do modelo em determinar a classificação correta das classes. Instrumentos que produzem assinaturas visuais muito bem delineadas no espectrograma obtiveram métricas de excelência: a Voz (*voi*) atingiu um *F1-Score* de 0,96, enquanto o Piano (*pia*) e o Órgão (*org*) cravaram 0,93.

No entanto, registrou-se uma confusão esperada em grupos específicos de instrumentos, devido à forte sobreposição de seus harmônicos e técnicas de excitação da nota. Classes como o Saxofone (*F1-Score* de 0,79) e a Guitarra Elétrica (*F1-Score* de 0,80) apresentaram as maiores margens de erro relativo. Isso evidencia que timbres muito semelhantes, onde a distorção do sinal ou o sopro geram ruídos difusos na imagem, exigem estratégias futuras de regularização focadas exclusivamente nestas microtexturas do espectrograma.

TABLE III
DESEMPENHO POR CLASSE DO MODELO RESNET50

Instrumento	Precisão	Recall	F1-Score
CEL (Violoncelo)	0,93	0,86	0,89
CLA (Clarinete)	0,79	0,90	0,84
FLU (Flauta)	0,90	0,78	0,84
GAC (Violão Acústico)	0,83	0,91	0,87
GEL (Guitarra Elétrica)	0,77	0,83	0,80
ORG (Órgão)	0,94	0,91	0,93
PIA (Piano)	0,95	0,92	0,93
SAX (Saxofone)	0,75	0,84	0,79
TRU (Trompete)	0,96	0,86	0,91
VIO (Violino)	0,90	0,74	0,81
VOI (Voz)	0,94	0,98	0,96

V. CONCLUSÃO

Este trabalho validou a premissa de que a representação bidimensional de sinais acústicos através de espectrogramas Mel, quando processada por redes neurais convolucionais profundas, supera drasticamente a extração clássica de características baseada em vetores MFCC. Enquanto o modelo *baseline* (*Random Forest*) apresentou um cenário de sobreajuste acentuado, com acurácia de treinamento de 99,89% mas apenas 54,61% na validação, a arquitetura *ResNet50* demonstrou uma capacidade de generalização superior, atingindo uma acurácia global de 87,30% no conjunto de teste invisível.

As etapas de refinamento metodológico foram determinantes para esses resultados. O uso de técnicas de *Data Augmentation* bidimensional, como o mascaramento temporal e frequencial, permitiu expandir a base de treinamento de 4.688 para 37.504 amostras, mitigando o *overfitting* na rede profunda. O desempenho de excelência em classes como Voz (*F1-Score* de 0,96) e Piano (*F1-Score* de 0,93) comprova que o modelo aprendeu a identificar texturas harmônicas e dinâmicas de ataque que são colapsadas em médias estatísticas simples.

Contudo, observou-se que o aumento da precisão acarreta um custo computacional elevado, com o modelo robusto ocupando $\approx$ 98 MB de memória, contra $\approx$ 4 MB do *baseline*. Em suma, o projeto ratifica o papel do *Deep Learning* como a abordagem de vanguarda para o reconhecimento complexo de timbres musicais.

REFERENCES

[1] A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, *Dive into Deep Learning*. Cambridge University Press, 2020.

[2] J. J. Bosch, R. Togneri, and D. van Tassel, "IRMAS: A dataset for instrument recognition in musical audio signals," in *Proc. International Society for Music Information Retrieval Conference (ISMIR)*, 2014.

[3] B. McFee et al., "librosa: Audio and music signal analysis in python," in *Proceedings of the 14th Python in Science Conference*, 2015, pp. 18–24.

[4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[6] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.

[7] TorchAudio Developers, "TorchAudio Documentation," PyTorch. [Online]. Available: https://pytorch.org/audio/stable/index.html. Accessed: 2026.

[8] A. Ferreira and R. P. Dionísio, "Espectrograma de Sinais," Instituto Politécnico de Castelo Branco, Portugal, 2015.